

Sensoriamento espectral por detecção de energia utilizando aprendizagem por reforço

Rafael Rodrigo Nicolay¹, Lauro Tremea Culau¹, Matheus Eidt¹,
Matias Schimuneck¹, Roberto Schmidt¹, Maicon Kist², Cristiano Both¹

¹Universidade de Santa Cruz do Sul

²Universidade Federal do Rio Grande do Sul

{rafaelrodrigo, laurotc, matiass, matheus, rmainardi}@mx2.unisc.br,
maicon.kist@inf.ufrgs.br, cboth@unisc.br

Resumo—A demanda por recursos de rede sem fio tem aumentado consideravelmente nos últimos anos. A alocação espectral de forma estática, usada atualmente, não conseguirá atender essa alta demanda nos próximos anos. Uma alternativa para o problema causado pela alocação espectral de forma estática é a adoção de Rádios Cognitivos. Estes dispositivos são capazes de analisar e se adaptar ao estado atual de utilização do espectro de radiofrequências, utilizando temporariamente canais livres de forma oportunista e dinâmica em suas comunicações. Para que o acesso oportunista ocorra, é necessário garantir a ociosidade do canal de comunicação que será usado pelo dispositivo, de forma a evitar quaisquer interferências danosas a outros usuários. A descoberta de canais ociosos no espectro de radiofrequências é feita através do sensoriamento espectral. Este processo consiste na obtenção de conhecimento sobre o uso do espectro de radiofrequência em uma determinada localização geográfica, com o objetivo de encontrar oportunidades de acesso para realizar a comunicação. Este trabalho propõe uma melhoria na técnica de Sensoriamento por Detecção de Energia. Esta técnica utiliza um limiar para diferenciar um canal de radiofrequência livre de um ocupado. Para realizar essa melhoria foi utilizado o SARSA, um algoritmo de Aprendizado por Reforço. Os resultados obtidos nos experimentos mostram um ganho de desempenho em relação ao uso do algoritmo Bayesiano.

I. INTRODUÇÃO

O espectro de Radiofrequências (RF) é um recurso natural que tem seu uso licenciado por órgãos reguladores dos governos, como a *Federal Communications Commission* (FCC), nos Estados Unidos e a Agência Nacional de Telecomunicações (Anatel), no Brasil. No modelo atual de alocação do espectro de RF, os órgãos reguladores reservam e alocam canais do espectro para concessionárias, garantindo a elas total direito sobre um determinado canal. As concessionárias que possuem direito de uso sobre um canal são chamadas de Usuários Primários (UPs), pois possuem garantias de que nenhum outro usuário irá interferir na comunicação [1]. Como exemplos de UPs pode-se citar emissoras de rádio e televisão.

Um estudo realizado pela FCC expõe a ineficiência do modelo atual de alocação [2]. Segundo o estudo, os canais de RF reservados apresentam baixa taxa de utilização. Um exemplo típico é a transmissão de canais de televisão, que possuem uma ampla faixa do espectro de RF licenciada. Entretanto, na maioria dos municípios, poucas emissoras de TV atuam, levando a uma subutilização dos canais reservados. Desta forma, a FCC propôs um novo modelo de alocação, em que Usuários Secundários (USs), que não possuem direito de acesso sobre o canal, possam utilizar os canais que estão ociosos de forma oportunista, isto é, temporariamente e sem causar interferência aos UPs. Esta técnica é comumente denominada *Dynamic Spectrum Access* (DSA).

Diante deste cenário, o Rádio Cognitivo (RC) surge como uma das principais tecnologias que possibilitam o acesso oportunista ao espectro de forma eficiente [3]. RC é um

dispositivo capaz de analisar a utilização do espectro de RF e adaptar seus parâmetros de transmissão de forma dinâmica e autônoma, para maximizar a transferência de dados, mitigar a interferência ou facilitar a interoperabilidade. O principal requisito para a utilização de RCs é o sensoriamento espectral, responsável por analisar o espectro de RF em busca de canais não utilizados ou ociosos [4]. Dentre as técnicas de sensoriamento espectral dispostas na literatura, a Detecção de Energia (ED) é a que apresenta menor complexidade. Esta técnica utiliza de uma comparação de um limiar com a energia do canal de comunicação para classificá-lo quanto a sua ociosidade. Entretanto, o uso de um limiar estático prejudica sua precisão, ou seja, a taxa de acertos na classificação de canais de RF.

Este trabalho propõe uma melhoria à técnica de ED, visando aumentar a eficiência na detecção, mantendo baixo o tempo necessário na classificação. Para realizar esta melhoria foi utilizado o algoritmo SARSA (*State-Action-Reward-State-Action*), que tem por objetivo ajustar fatores que maximizem a eficiência de classificação, de acordo com o histórico de classificações realizadas anteriormente. Para realizar a validação da melhoria proposta será realizada uma comparação com o algoritmo Bayesiano.

O restante desse trabalho está organizado da seguinte maneira: Na Seção II são apresentados os conceitos necessários para a correta compreensão deste trabalho. A Seção III apresenta trabalhos que têm características em comum com este. A arquitetura e a modelagem do algoritmo é abordada na Seção IV. Já na Seção V é descrita a metodologia de avaliação do módulo proposto. A Seção VI apresenta os resultados obtidos a partir dos experimentos realizados. Por fim, a Seção VII apresenta as considerações finais.

II. Sensoriamento Espectral

O principal requisito para a implementação de RCs é a capacidade de detectar os *white spaces* (espaços ociosos) do espectro de RF. Através do sensoriamento espectral o equipamento analisa, determina as características de utilização e obtém as regiões não utilizadas do espectro de frequências. O sensoriamento espectral deve encontrar canais livres em um curto intervalo de tempo, pois quanto mais rápido é o sensoriamento, maior é a utilização do espectro de RF ocioso. Além disso, o sensoriamento deve ter alta precisão para que aproveite todas as oportunidades de espectro sem causar interferências aos UPs.

As técnicas de sensoriamento espectral podem ser divididas em dois grandes grupos. No sensoriamento local são utilizadas apenas informações observadas pelo dispositivo que efetua o sensoriamento. Já no sensoriamento cooperativo há a comuni-

cação entre dispositivos, desta forma é possível atingir maior precisão nos resultados.

A ED é a técnica mais comum dentre os algoritmos de sensoriamento espectral, devido a sua baixa complexidade computacional e de implementação [5]. Essa técnica é mais genérica do que outras técnicas de sensoriamento local, pois os dispositivos de RC não precisam ter nenhum conhecimento sobre o sinal do UP. O sinal é detectado comparando energia de um sinal recebido com um limiar que depende do nível de ruído [6]. Os maiores desafios do ED incluem a seleção do limiar correto para detectar UPs, incapacidade de diferenciar UP de ruído, e desempenho baixo quando a relação sinal/ruído (*Signal-to-Noise Ratio*, ou SNR) é baixa [7].

Outra técnica de sensoriamento local encontrada na literatura é a Detecção por Formato de Onda. Esta técnica consiste em procurar por padrões no sinal de comunicação recebido. Estes padrões podem ser identificados se parâmetros como preâmbulos e códigos de espalhamento são conhecidos. O desempenho desta técnica é superior à ED, porém o custo de tempo por sensoriamento é maior.

A. Rádios Cognitivos

O termo “rádio cognitivo” foi definido inicialmente por Mitola e Maguire como o ponto em que os dispositivos sem fio e as redes destes dispositivos são inteligentes sobre os recursos de rádio, de tal forma que detectam as necessidades de comunicação do usuário em função do contexto de uso. E provém recursos e serviços que atendam essas necessidades apropriadamente [8]. Mais recentemente, a FCC definiu o termo “rádio cognitivo” em um sentido mais estrito, como sendo dispositivos de comunicação capazes de analisar a utilização do espectro de RF e adaptar seus parâmetros de transmissão dinâmica e autonomamente, para maximizar a transferência de dados, mitigar a interferência, facilitar a interoperabilidade ou acessar mercados secundários.

O Rádio Cognitivo surge como uma das principais tecnologias que possibilitam o acesso oportunista ao espectro de forma eficiente [3]. Uma aplicação de RCs é o DSA, que consiste em permitir o uso de forma temporária das regiões reservadas do espectro que encontrem-se ociosas, comumente denominadas de *white spaces*.

O RC possui duas características principais: capacidade cognitiva e reconfigurabilidade. A capacidade cognitiva é a habilidade do dispositivo de observar e capturar o estado de utilização do espectro de RF no ambiente no qual se encontra [9]. Em outras palavras, dispositivos de rádio com capacidade cognitiva são capazes de aprender quais são os melhores canais para realizar a comunicação no espectro de RF. A reconfigurabilidade, por sua vez, é a capacidade do dispositivo mudar dinamicamente os seus parâmetros de configuração de acordo com o ambiente de rádio.

B. Aprendizado por Reforço

O Aprendizado de Máquina pode ser definido como um conjunto de algoritmos e técnicas que possibilitam que um computador aprenda algo, isto é, que permitam ao computador aperfeiçoar seu desempenho em alguma tarefa. No contexto dos algoritmos de aprendizagem de máquina, existe a figura do agente. Um agente é uma entidade imersa no ambiente no qual é capaz de agir. O agente dispõe de uma capacidade de percepção e de representação parcial deste ambiente. Além disso, o agente possui um comportamento autônomo, consequência de suas observações sobre o ambiente e de seu conhecimento.

O Aprendizado por Reforço (AR) é uma das técnicas de Aprendizado de Máquina. O AR aprende pelo método de

tentativa e erro (*trial-and-error*), onde sua cognição é atendida através da interação, sem qualquer conhecimento prévio, com o ambiente. Outra característica do AR é a recompensa atrasada (*delayed reward*). Esta recompensa é uma informação que o agente recebe após executar uma ação. A recompensa pode ser positiva, se a ação executada pelo agente foi boa, ou negativa, se a ação executada foi prejudicial [10]. O problema consiste em escolher ações que maximizem o total de recompensas positivas recebidas pelo agente [11].

A ideia principal do algoritmo SARSA, que é utilizado nesse trabalho, é aprender com o retorno associado a cada ação em cada estado. Por exemplo, considerando um estado de execução e a necessidade de executar uma determinada ação, isso irá gerar uma recompensa, positiva ou não, que será utilizada para quantificar o quão correta foi a ação tomada neste estado. Com o valor obtido, é gerado um histórico, ou então uma política de seleção de ações, que irá ajudar na próxima tomada de decisão deste estado a fim de aperfeiçoar sua tomada de decisões para melhorar seu desempenho.

III. TRABALHOS RELACIONADOS

No trabalho realizado por Akyildiz [12] um algoritmo de sensoriamento cooperativo baseado em AR foi proposto. Os objetivos dos autores do trabalho se resumem em descobrir o conjunto ótimo de vizinhos para cooperação que gere o mínimo de tráfego de controle na rede, minimizar o *delay* causado pela cooperação e minimizar o consumo de energia decorrente da cooperação.

No trabalho de Oksanen [13], assim como no trabalho apresentado anteriormente, é proposto uma política de sensoriamento espectral cooperativo baseada em Aprendizado por Reforço. A política tem a função de decidir quais canais serão sensoreados e qual US fará o sensoriamento. Os objetivos do trabalho são maximizar a taxa de transmissão de USs, alcançar eficiência energética, minimizar perdas de detecções e se adaptar as condições do espectro de radiofrequências.

Pode-se perceber que os trabalhos prezam pela diminuição do *delay* e pela redução do consumo de energia ocasionado pela cooperação entre USs. Este trabalho propõe o uso de aprendizagem em sensoriamento local, objetivando alta eficiência e rapidez na detecção de UPs.

IV. MÓDULO DE AJUSTE DINÂMICO DE LIMIAR

O módulo de ajuste dinâmico de limiar tem a função de ajustar em tempo real o limiar utilizado na classificação de canais de radiofrequência. O limiar deve se adequar rapidamente a mudanças nas propriedades da onda de sinal sendo analisada, para que alta precisão seja alcançada. A seguir descreve-se a arquitetura do módulo e como foi realizada a modelagem do algoritmo SARSA.

A. Descrição do Módulo

O módulo proposto executa em um *front-end* de rádio, realizando a análise sobre os sinais de RF capturados. Para o desenvolvimento do módulo foi utilizado o *Universal Software Radio Peripheral 2* (USRP2) que consiste em um *front-end* de rádio, flexível e de baixo custo, desenvolvido pela *Ettus Research*.

A programação ocorreu utilizando a linguagem Python e o software GNU Radio. Esse software apresenta um conjunto de módulos que permitem a realização do processamento de sinais de RF capturados pelo USRP2.

B. Funcionamento

A arquitetura resultante da integração entre o Detector de Energia e o algoritmo SARSA é ilustrada na Figura 1. O bloco “Vetorização” é responsável por agrupar o fluxo de dados, recebido do USRP2, e armazena-los em um vetor. Esta operação é necessária para facilitar as demais manipulações de sinais. Já o bloco “Definição Janela” tem a função de dividir o vetor de dados repassado pelo bloco citado anteriormente em grupos contendo N elementos, onde N é o tamanho da janela de observação. Na experimentação, o valor da janela de observação foi fixado em 1024 amostras de sinal. O bloco “FFT” aplica a Transformada Rápida de Fourier (“Fast Fourier Transform”, ou FFT) em cada conjunto de dados enviado pelo bloco “Definição Janela”. A FFT tem o objetivo de transformar o sinal no domínio tempo para o domínio de frequência ou vice-versa. Tanto a entrada como a saída de dados deste bloco é um vetor de números complexos.

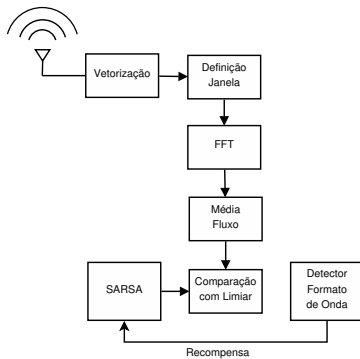


Figura 1. Arquitetura do Detector de Energia

O bloco “Média Fluxo” tem a finalidade de calcular a média de energia presente nos N valores que representam a janela de observação. Este bloco produz uma única saída para cada janela de observação avaliada. Este valor é comparado com o valor do limiar fornecido pelo algoritmo SARSA no bloco denominado “Comparação com Limiar”. As escolhas possíveis são: ocupado, se o valor de energia for maior que o limiar, ou ocioso, caso contrário. O reforço utilizado pelo algoritmo SARSA é fornecido por um Detector por Formato de Onda, localizado no bloco “Detector Formato de Onda”. Visto que o sensoriamento por Formato de Onda exige mais processamento, o reforço não é enviado ao algoritmo a cada sensoriamento.

Para adaptar o algoritmo SARSA ao Detector de Energia, o problema é modelado como um conjunto finito de estados s e um conjunto finito de ações a . O conjunto de estados s será representado pelos possíveis valores do limiar utilizado na classificação. Supondo que o número de estados seja definido como N , os estados possíveis seriam $(S_1, S_2, S_3, \dots, S_N)$, onde S_1 representa o menor valor possível do limiar, e S_N representa o maior valor. As ações possíveis são: manter o valor do limiar (A_1), aumentar o limiar (A_2) ou diminuir o limiar (A_3). Desta forma, se a ação de diminuir o valor do limiar for tomada, o próximo estado será o estado que represente um valor menor do limiar. A Figura 2 ilustra a modelagem utilizada.




Figura 2. Modelagem Utilizada para Ajuste do Limiar

V. AVALIAÇÃO DO MÓDULO

Esta seção apresenta detalhes da metodologia utilizada para avaliação do algoritmo de sensoriamento espectral proposto. A seguir, apresenta-se o ambiente de testes utilizado para execução dos experimentos e o cenário de avaliação.

A. Ambiente de Experimentação

Para testar o desempenho do módulo desenvolvido será realizada a comparação com o algoritmo Bayesiano. Ambos algoritmos tem a função de controlar o limiar a ser utilizado no sensoriamento por ED.

O algoritmo Bayesiano, diferentemente do SARSA, utiliza um modelo probabilístico na escolha do limiar a ser utilizado. Cada limiar está associado a um “risco”, que é atualizado ao decorrer da execução do algoritmo. Os limiares que diminuem a precisão do algoritmo tendem a ser relacionados com riscos maiores. Desta forma, o limiar utilizado é o que apresenta o menor risco.

B. Cenário de Avaliação

A validação deste trabalho foi realizada através da criação de um cenário de RF controlado. Neste cenário, o UP é representado por um gerador de sinais, que esporadicamente realiza alguma transmissão. Enquanto que o US é representado por um USRP2. Este cenário é ilustrado na Figura 3. O US deve detectar o mais rápido possível quando o gerador de sinais interrompeu sua transmissão e sinalizar que o canal está disponível. Da mesma forma, quando o gerador voltar a transmitir, o canal deve ser dado como ocupado.



Figura 3. Cenário de Testes

Para que seja possível realizar uma comparação justa entre o algoritmo SARSA e o Bayesiano, o sinal foi gerado e após armazenado na memória de um computador. O sinal utilizado foi definido segundo uma distribuição de Poisson com média e variância (λ) igual a 10. Desta forma, não é preciso capturar o sinal de RF a cada execução e pode-se avaliar o desempenho de ambos algoritmos sobre o mesmo sinal de transmissão.

VI. RESULTADOS

Nesta seção são apresentados os resultados obtidos após uma série de repetições dos experimentos. Os algoritmos foram comparados quanto ao processamento e ao tempo necessário na classificação de canais de RF. Para avaliar o tempo de execução de cada algoritmo, os mesmos foram isolados do restante do projeto. Desta forma é possível conhecer com maior precisão o tempo gasto exclusivamente pelos algoritmos

no processo de sensoriamento. Foram realizadas 20 execuções para cada quantidade de ciclos avaliada.

O tempo necessário para realizar o sensoriamento pelo algoritmo SARSA foi de 68.5% do tempo gasto pelo algoritmo Bayesiano. A Figura 4 ilustra a comparação de tempo entre os algoritmos. Por exemplo, para completar 100000 ciclos, o algoritmo SARSA demora 0.85 segundos, enquanto o Bayesiano precisa de 1.25 segundos para concluir.

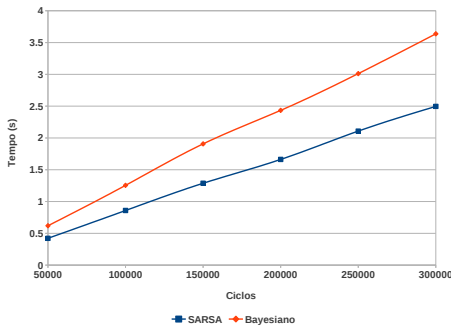


Figura 4. Comparação do Tempo de Execução

Já para medir a precisão dos algoritmos, foram realizados no total de 20 execuções sobre o sinal de radiofrequência armazenado, para cada algoritmo. O sinal de radiofrequência utilizado gera cerca de 80000 sensoriamentos, e o número de reforços recebidos pelos algoritmos é de, aproximadamente, 400 por execução.

Para calcular a precisão dos algoritmos é realizada uma comparação com o resultado ótimo. No que se deve à precisão de acertos, o SARSA supera levemente o Bayesiano. Enquanto que o algoritmo Bayesiano obteve precisão de 99.39%, o algoritmo SARSA obteve 99.46%. Porém o algoritmo Bayesiano é mais estável, ou seja, seus resultados são semelhantes a cada execução. A Figura 5 exibe uma comparação quanto à precisão dos algoritmos.




Figura 5. Comparação da Precisão

A Tabela I apresenta as médias de precisão de ambos os algoritmos, bem como seu desvio padrão. Observa-se que o SARSA apresenta maior variabilidade do que o Bayesiano, devido ao fato deste algoritmo utilizar do método de tentativa e erro na escolha das ações a serem executadas.

Algoritmo	Precisão	
	(%)	Desvio Padrão (%)
SARSA	99.46	0.0050
Bayesiano	99.39	0.0001

Tabela I
COMPARAÇÃO ENTRE ALGORITMO SARSA E BAYESIANO

VII. CONCLUSÃO E TRABALHOS FUTUROS

O sensoriamento espectral tem a função de analisar o espectro de RF em busca de canais não utilizados ou ociosos. É importante que este processo seja o mais rápido possível para que o espectro de radiofrequência ocioso seja bem aproveitado. E deve também ter alta precisão para que aproveite todas as oportunidades de espectro sem causar interferências aos UPs. Este trabalho propõe uma técnica de sensoriamento espectral local e inteligente, objetivando alta eficiência, rapidez na detecção de UPs e menor consumo de energia.

Após a etapa de modelagem do algoritmo SARSA, foi desenvolvido o módulo de controle dinâmico do limiar de um ED. Realizaram-se experimentos para caracterizar o tempo e precisão de sensoriamento. Os resultados mostraram que o uso de AR, mais precisamente do algoritmo SARSA, apresenta ótimos resultados no controle do limiar, superando o algoritmo Bayesiano tanto em precisão quanto em velocidade.

Como trabalhos futuros, estuda-se a construção de um sistema de sensoriamento cooperativo, onde a interação entre dispositivos possa ajudar a corrigir problemas oriundos das transmissões sem fio, como por exemplo, alto ruído e desvanecimento do sinal.

REFERÊNCIAS

- [1] J. Wang, M. Ghosh, and K. S. Challapali, "Emerging cognitive radio applications: A survey," *IEEE Communications Magazine*, vol. 49, pp. 74–81, 2011.
- [2] "Report of the Spectrum Efficiency Working Group," FCC, Tech. Rep., Nov. 2002.
- [3] A. Ghasemi and E. S. Sousa, "Spectrum sensing in cognitive radio networks: the cooperation-processing tradeoff," *Wireless Communications and Mobile Computing*, vol. 7, no. 9, pp. 1049–1060, 2007.
- [4] T. Yucek and H. Arslan, "A survey of spectrum sensing algorithms for cognitive radio applications," *Communications Surveys & Tutorials, IEEE*, vol. 11, Mar. 2009.
- [5] *KNOWS: Cognitive Radio Networks Over White Spaces*, 2007.
- [6] H. Urkowitz, "Energy detection of unknown deterministic signals," *Proceedings of the IEEE*, vol. 55, no. 4, pp. 523–531, 1967.
- [7] H. Tang, "Some physical layer issues of wide-band cognitive radio systems," in *First IEEE International Symposium on New Frontiers in Dynamic Spectrum Access Networks*, 2005. *DySPAN 2005*. IEEE, 2005.
- [8] J. Mitola and G. Q. Maguire, "Cognitive radio: making software radios more personal," *Personal Communications, IEEE*, vol. 6, Aug. 1999.
- [9] T. Jiang, D. Grace, and P. D. Mitchell, "Efficient exploration in reinforcement learning-based cognitive radio spectrum sharing," *Communications, IET*, Jul. 2011.
- [10] M. Bkassiny, Y. Li, and S. Jayaweera, "A survey on machine-learning techniques in cognitive radios," *Communications Surveys Tutorials, IEEE*, vol. PP, no. 99, pp. 1–24, 2012.
- [11] L. Busoni, R. Babuska, and B. De Schutter, "A comprehensive survey of multiagent reinforcement learning," *Trans. Sys. Man Cyber Part C*, vol. 38, no. 2, pp. 156–172, Mar. 2008.
- [12] B. Lo and I. Akyildiz, "Reinforcement learning-based cooperative sensing in cognitive radio ad hoc networks," in *Personal Indoor and Mobile Radio Communications (PIMRC), 2010 IEEE 21st International Symposium on*, 2010, pp. 2244–2249.
- [13] J. Oksanen, J. Lundén, and V. Koivunen, "Reinforcement learning based sensing policy optimization for energy efficient cognitive radio networks," *Neurocomput.*, vol. 80, pp. 102–110, Mar. 2012.