

# Uma Abordagem sobre Computação Proativa e Predição em Aplicações Sensíveis ao Contexto

Rodrigo Simon Bavaresco<sup>1</sup>

<sup>1</sup>Universidade do Vale do Rio dos Sinos (UNISINOS)  
Av. Unisinos, 950 – Cristo Rei, São Leopoldo – RS, 93022-000

guigobavaresco@gmail.com

**Abstract.** *This article presents a research that exposes fundamental concepts for the context histories exploration, highlighting a subject considered as a trend in the area of ubiquitous computing, called context prediction. It emphasizes the need to incorporate proactivity in context-aware applications, and discusses current challenges and issues related to environment adaptation. During this work, three relevant prediction architectures are presented and compared, and finishes with prediction state of the art.*

**Resumo.** *Este artigo apresenta uma pesquisa que expõe conceitos fundamentais para a exploração do histórico de contextos, evidenciando um tema considerado como tendência na área da computação ubíqua, a predição de contexto. Ressalta-se a necessidade de incorporar proatividade nas aplicações sensíveis ao contexto, e aborda-se os desafios atuais e questões pertinentes à adaptação ao ambiente. No decorrer do trabalho, três relevantes arquiteturas de predição são apresentadas e comparadas, e finaliza-se com a exposição do estado da arte em predição.*

## 1. Introdução

Escrito em 1991 e marco inicial da computação ubíqua, *The Computer of 21's Century* foi o artigo onde Mark Weiser [Weiser 1991] afirmou: “elementos de hardware e software serão tão ubíquos que ninguém irá notar suas presenças”. Atualmente afirma-se que os sistemas estão sendo aprimorados cada vez mais para preencher o espaço previsto por Weiser, como é o caso das aplicações sensíveis ao contexto. Para alcançar a excelência na ubiquidade precisa-se ainda tornar estas aplicações mais adaptativas ao ambiente, fornecendo serviços dinâmica e proativamente sem uma explícita intervenção do usuário [Ameyed et al. 2015]. Desta forma, estaremos aptos a resolver os desafios identificados por Weiser, fornecendo computação proativa e não reativa.

Segundo Mayrhofer [Mayrhofer 2005], a proatividade permite prover ao usuário interações que estejam em conformidade com as expectativas do mesmo. Em combinação com a sensibilidade ao contexto, abre inúmeras possibilidades para melhorar os serviços de informação disponíveis ou construir novos, atualmente indisponíveis. Entretanto, as pesquisas em sistemas antecipatórios e proativos, incluindo predição de situações futuras, estão ainda sendo aprimoradas.

Com o objetivo de fornecer para a literatura atual conceitos, desafios, arquiteturas existentes, definições essenciais para a construção de aplicações e o estado da arte direcionados à proatividade e predição na computação ubíqua, esta pesquisa aborda na seção 2 a evolução da sensibilidade ao contexto, na seção 3 a utilização da computação proativa, na seção 4 predição de contexto e por fim o estado da arte.

## **2. Sensibilidade ao Contexto**

No início do século 21, conforme as previsões de Weiser encontrava-se um cenário onde com maior frequência o computador pessoal deixava de ser um componente estático de mesa e a computação móvel expandia-se cada vez mais. Um fato existente na época era que os sistemas não estavam preparados para suportar a troca de ambientes físicos e diversas novas situações de uso, mesmo com a expansão de sistemas de localização apresentada por Hightower e Boriello [Hightower and Borriello 2001], proporcionando ao usuário experiências não tão agradáveis. Assim, considerava-se importante o questionamento a seguir como tópico de pesquisas: como adaptar os dispositivos diante da mudança do ambiente ao seu redor, melhorando a experiência do usuário?

Foi com a organização de pensamento apresentada anteriormente que Dey [Dey et al. 2001] introduziu o conceito de contexto, onde definiu-o brevemente como qualquer informação que caracterize uma situação relacionada com a interação entre usuário, aplicações e o ambiente ao seu redor. Contudo, uma nova área de pesquisa ganhava forças diante da computação ubíqua e era caracterizada pelos desafios da computação sensível ao contexto.

### **2.1. Definição de contexto**

Algumas definições já tinham sido exploradas na época, porém Dey afirmou que nenhuma delas ajudava a decidir se os interesses e preferências dos usuário seriam informações de contexto.

Desta forma, englobando uma série de definições prévias, inclusive uma feita pelo próprio autor, concluiu: “qualquer informação que possa ser usada para caracterizar a situação de entidades (ou seja, uma pessoa, lugar ou objeto) que são consideradas relevantes para a interação entre um usuário e uma aplicação, incluindo o usuário e a aplicação em si. Contexto é tipicamente a localização, a identidade e estado de pessoas, grupos e objetos computacionais e físicos.” Assim, buscou uma definição mais genérica aderente ao âmbito computacional.

### **2.2. Histórico de Contexto**

Se olharmos para o contexto em um momento do tempo, a recuperação e análise de determinados dados caracteriza um perfil de usuário. Uma das possibilidades de aplicações sensíveis ao contexto é a tomada de decisões e sugestões diante um novo contexto e o perfil do usuário em questão. Conforme citado por Silva [Silva et al. 2010] seria útil também considerar as ações do usuário feitas no passado em contextos visitados, tais como atividades realizadas, aplicações utilizadas, conteúdos acessados e qualquer outro possível evento. Assim, possuindo maior quantidade de informação, pode-se melhorar os objetivos das aplicações e tornar a experiência para o usuário mais agradável e com qualidade na tomada de decisões. Para isso se tornar viável é necessário que o registro da visita

nos contextos seja gravado, bem como suas ações em relação aos mesmos, ou seja, que tenha-se o histórico dos contextos. Além disso, se o contexto atual e o histórico dos contextos estiverem disponíveis para uma aplicação, abre-se outra possibilidade no âmbito da computação ubíqua, a de inferência para predição de contextos futuros.

Considerado por Mayrhofer como último desafio na exploração de histórico de contexto e tema atual de pesquisas, nas seções a seguir serão abordados conceitos relevantes sobre proatividade e predição de contexto.

### 3. Computação Proativa

Na área da ciência da computação encontra-se dois tipos de sistemas que atuam em tempos diferentes sob dados adquiridos, eventos e ações dos usuários. Denomina-se sistemas reativos aqueles que reagem à alguma situação identificada, como mudanças no estado de uma aplicação, e proativos os que têm conhecimento prévio sob estas possíveis situações e mudanças. Estes últimos irão computar com antecedência para tomar decisões antecipadas em benefício do usuário. Possuindo larga escala de utilização, hoje os agentes de software são os componentes modelados para fornecer proatividade às aplicações [Mayrhofer 2004].

De acordo com Mayrhofer, “além de melhorar a interação humano-computador que é necessário para a maioria das aplicações, a introdução da proatividade abre novas possibilidades para automatizá-las”. Contudo, o ganho em aplicações sensíveis ao contexto é expressivo principalmente para prover e obter serviços antecipadamente, adaptando-se melhor às mudanças de ambiente.

#### 3.1. Aplicações sensíveis ao contexto proativas

Atualmente a maioria das aplicações sensíveis ao contexto não incorporam comportamento proativo. Pode-se encontrar trabalhos que, baseado no histórico de contexto, processem informações e descrevam uma entidade para personalizar a aplicação em questão, fazendo com que a mesma torne-se reativa de acordo com o perfil do usuário [Wagner et al. 2014].

Para este cenário é fundamental que além de considerar o histórico de contexto para definições do perfil, as aplicações utilizem-no para inferir em contextos futuros. Sendo assim, dependendo do ambiente e do perfil do usuário, deve-se oferecer de forma proativa serviços adequados, e ir automaticamente adaptando-se para descobrir contextos e mudanças no comportamento da aplicação [Ameyed et al. 2015]. Inúmeros são os desafios deste comportamento e cita-se cinco de acordo com as visões de Mayrhofer: acurácia dos dados gravados, tolerância a falhas ocorridas nos sensores, operações discretas que não interfiram nas atividades do indivíduo, aceitação da aplicação perante o usuário e por fim sua privacidade.

#### 3.2. Adaptação proativa

A adaptação das aplicações em relação ao ambiente é um dos pontos relevantes da computação ubíqua e fundamental para melhorar a experiência do usuário. De fato, as mesmas estarão operando entre diversos serviços, normalmente exposto sob redes móveis e processando inúmeras informações de contexto para alterações próprias de comportamento. Ameyed et al. citam que diversos tipos de adaptação podem ser diferenciados:

adaptação baseada em conteúdo, adaptação baseada em comportamento, adaptação baseada na apresentação (interface) e adaptação de componentes de sistema, e apresentam uma divisão para o controle em manual, automático e automaticamente genérico. Este último é o único que pode responder a eventos inesperados, refinando e melhorando seu comportamento ao longo do tempo.

Entretanto, Ameyed et al. salientam diversos problemas no processo de adaptação que envolvem, por exemplo, a extração do conhecimento. Algumas atividades podem ser citadas, tais como a capacidade de reconhecer, identificar e modelar o conhecimento relevante para o processo de adaptação. Para os autores, este problema pode ser apresentado como uma criação de inteligência: analisar informações de contexto, deduzir o sentido e construir o conhecimento. Outros desafios também são abordados e envolvem tolerância a falhas, recuperação em caso de falha e a habilidade de descobrir recursos e criar novas estratégias para responder a entradas inesperadas.

#### **4. Predição de Contexto**

A predição de contexto é uma habilidade que pode ser realizada por aplicações sensíveis ao contexto que tenham conhecimento do histórico de contexto e do contexto atual de uma entidade. Considera-se esta habilidade proativa, e formaliza-se como objetivo identificar contextos futuros que provavelmente irão descrever a situação da entidade em questão. Desta forma, obter e prover serviços de forma proativa implicará em benefícios para adaptação das aplicações ao ambiente ao seu redor.

Nas seções anteriores foram apresentados conceitos fundamentais como base para explorar a predição de contexto diante a computação ubíqua. Além disso, para a criação de um modelo de predição, são diversas as necessidades e requisitos que devem ser considerados, tais como: um período adequado de histórico de contextos, aquisição de dados de sensores, níveis de abstração dos contextos envolvidos, capacidade de aprendizado, algoritmos de predição, privacidade e uma definição formal de contexto, conforme explorado na seção 2 de [Rosa et al. 2016].

Atuando sobre as informações de contexto, deve-se usar algoritmos estatísticos e de *machine learning* para monitorar e extrapolar históricos de contexto, com o objetivo de aprender e aplicar esse conhecimento para prever contextos futuros [Mayrhofer 2004]. Estes processos também incorporam diversos problemas, como a complexidade na execução de algoritmos, na utilização de predições incertas no mundo real, processamento em tempo real para o aprendizado, heterogeneidade de valores para aplicação de algoritmos, entre outros problemas abordados por Mayrhofer. A seguir será discutido algumas arquiteturas presentes na literatura.

##### **4.1. Comparação entre Arquiteturas**

Com relação aos princípios de uma arquitetura flexível, os trabalhos apresentados a seguir, no âmbito da predição de contexto, aderem a modularização, interfaces dispostas entre camadas e responsabilidade única, constituindo suas devidas arquiteturas. Será abordado uma visão geral de três pesquisas relevantes para a área da computação ubíqua. As mesmas estão dispostas num intervalo de 6 anos para cada e constituem abordagens mais gerais, suportando essencialmente informações de contexto genéricas, considerado por Ameyed et al. [Ameyed et al. 2015] como um dos desafios em predição de contexto.

Conforme a figura 1, Mayrhofer [Mayrhofer 2004] expôs sua arquitetura baseada numa abordagem composta por 5 fases, relacionando-as nas seguintes camadas: aquisição de dados dos sensores, extração de características, classificação, rotulação e predição. A camada *Sensor Data Aquisition* fornece fluxo de dados em séries temporais das medições disponíveis. *Feature Extraction* refere-se a extração da informação por métodos de domínio específicos, a partir dos dados dos sensores. A camada *Classifier* compreende a tarefa de encontrar padrões no espaço de características da fase anterior, chamado de *classes*. Para facilitar o desenvolvimento de aplicações sensíveis ao contexto e de apresentar contextos detectados para o usuário, nomes descritivos devem ser atribuído às *classes* individuais ou combinadas, constituindo-se a camada *Labeling* e por último, a camada *Prediction* que é a etapa que gera *classes* futuras.

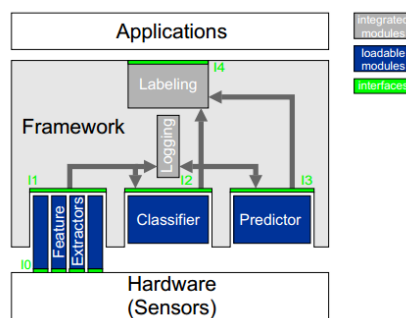


Figura 1. Arquitetura defendida por Mayrhofer [Mayrhofer 2004]

Meiners et al. [Meiners et al. 2010] propuseram uma abordagem para sistema de predição que pode ser usada como um componente reutilizável para aplicações sensíveis ao contexto. A camada *Learning* e a camada *Prediction* são processos concorrentes e independentes, interligadas pela camada *Knowledge*, que por sua vez constitui a camada de dados. A camada de aprendizado cria e atualiza conhecimentos e a camada de predição usa o conhecimento para as previsões que são realizadas por demanda. A camada *Data Acquisition* é responsável pela aquisição de dados de contexto, disponibilizando por meio de uma interface única e abstraída das interfaces físicas e dos sensores, conforme pode-se verificar na figura 2.




Figura 2. Arquitetura criada por Meiners et al. [Meiners et al. 2010]

Rosa et al. [Rosa et al. 2016] apresentaram uma arquitetura baseada no *design pattern* Model-View-Controller (MVC) constituída por três camadas, dois agentes, uma biblioteca com algoritmos de predição e históricos, ontologias e aplicações externas ao modelo central. O modelo realiza predições sobre entidades (uma pessoa, um objeto, um carro, etc.) por intermédio da interação das aplicações externas. É importante destacar que os agentes rodam de forma autônoma e concorrente com a aplicação. O *ONLearning Agent* monitora constantemente as histórias externas, a fim de detectar novas entradas que são copiadas para *ONHistories Dataset*. Ele também gera regras ou atualiza as já existentes armazenadas na *ONRules Dataset*. O agente *ONRanker*, por outro lado, percebe novas assinaturas (analisando *ONEntities Dataset*) ou mudanças nas regras (por meio do *ONRules Dataset*) e classifica para cada assinatura o melhor algoritmo de previsão. Desta forma a seleção do melhor algoritmo de previsão a ser aplicado em uma situação específica é automática. Além disso, a consideração de privacidade e um modelo formal de contexto são aspectos importantes da arquitetura proposta. A figura 3 apresenta esta arquitetura.

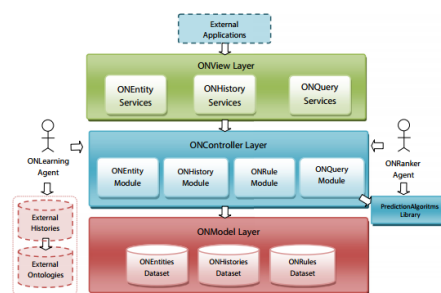


Figura 3. Arquitetura concebida por Rosa et al. [Rosa et al. 2016]

Em uma comparação, a tabela 1 reúne as arquiteturas relacionadas anteriormente levando em consideração 4 importantes requisitos: **aprendizado**, que faz referência a adesão de um módulo de aprendizado, fundamental para predição de contexto, **privacidade** identificada por Weiser [Weiser 1991] como um dos grandes desafios da computação ubíqua, **representação formal de contexto** que é fundamental para diferentes sistemas poderem comunicar-se [Rosa et al. 2016], e a **utilização de agentes de software** largamente explorado na computação proativa que beneficia a arquitetura como um todo.

Tabela 1. Comparação entre as arquiteturas apresentadas

	Aprendizado	Privacidade	Contexto Formal	Agentes
Mayrhofer	✓	-	-	-
Meiners et al.	✓	-	-	✓
Rosa et al.	✓	✓	✓	✓

Entretanto, salienta-se que as três arquiteturas possuem uma camada de predição. Esta camada é composta por métodos (contemplando algoritmos) que irão realizar computação sob determinada base de dados, com o objetivo de predição. Pode-se citar alguns métodos estudados na literatura atual [Ameyed et al. 2015]: *Sequence Prediction Approach*, *Markov Chains*, *Bayesian Network*, *Neural Networks*, *Branch Prediction*

*Method, Trajectory Prolongation Approach, Expert System* entre outros. Este métodos diferem em diversos critérios como acurácia, tolerância de valores faltantes, eficiência, escalabilidade e outros. Contudo, deve-se escolher o melhor método para determinada aplicação ou criar mecanismos de adaptação e seleção do algoritmo baseado na situação, como visto em [Rosa et al. 2016].

## 5. Estado da Arte

Atualmente grande parte das pesquisas presentes na literatura cujo o tema principal é predição de contexto concentram-se em mobilidade pessoal, criando assim aplicações baseadas em localização [Burbey and Martin 2012]. Abaixo relata-se como exemplos Noulas et al. [Noulas et al. 2012] e Horvitz e Krumm [Horvitz and Krumm 2012]. De fato, é importante considerar que em diversas outras áreas a predição beneficia o usuário. Conforme Pejovic e Musolesi [Pejovic and Musolesi 2015] as áreas de *assistentes pessoais tecnológicos, cuidados com a saúde e smart cities* tem recebido considerável atenção na criação de aplicações sensíveis ao contexto e predição. Segundo abordagem feita pelos próprios autores, abaixo é exemplificado algumas aplicações sobre mobilidade pessoal e assistentes pessoais tecnológicos.

Noulas et al. investigaram a previsão do próximo check-in na rede social Foursquare. Eles mostraram que uma abordagem de aprendizagem supervisionada que leva em consideração várias características, tais como o histórico dos locais visitados, a sua popularidade global, transições observadas entre categorias de locais, e outras características são necessárias para a predição com sucesso. Relacionado também com mobilidade, Horvitz e Krumm desenvolveram um método para prever o destino de um usuário, sugerindo que o usuário faça um desvio ideal interrompendo a sua viagem, por exemplo, para tomar um café. Com relação aos assistentes pessoais, em 2013 a Google [Google 2013] liberou a primeira versão do aplicativo que possui uma abordagem mais geral que as citadas previamente, e têm como objetivo fornecer a um usuário qualquer informação ou funcionalidade que o mesmo possa vir a precisar, sem que ele pergunte explicitamente por isso. Deve-se inclusive considerar o modelo abordado na seção anterior, proposto por Rosa et al. [Rosa et al. 2016], como contribuição atual para aplicações sensíveis ao contexto.

## 6. Conclusão

Por meio da pesquisa apresentada é possível compreender a evolução da sensibilidade ao contexto, analisando conceitos e definições fundamentais para a construção das aplicações sensíveis ao contexto.

De fato, o próximo e possivelmente último passo na exploração de histórico de contextos já foi dado, embora ainda não seja tão disseminado. Os modelos apresentados na seção 4.1 confirmam esta afirmação, e viabilizam a construção de aplicações, utilizando dados de contextos obtidos para aprendizado e inferência de contextos futuros.

Entretanto, os desafios em proatividade e adaptação citados nas seções 3.1 e 3.2 bem como os desafios em predição de contexto, elencados na seção 4 merecem considerável atenção nos próximos anos. Contudo, se forem resolvidas as problemáticas estaremos aptos a desenvolver aplicações cada vez mais conectadas e transparentes para o cotidiano dos usuários.

## Referências

- Ameyed, D., Miraoui, M., and Tadj, C. (2015). A survey of prediction approach in pervasive computing. *International Journal of Scientific & Engineering Research*, page 306–316.
- Burbey, I. and Martin, T. L. (2012). A survey on predicting personal mobility. *International Journal of Pervasive Computing and Communications*, page 5–22.
- Dey, A. K., Abowd, G. D., and Salber, D. (2001). A conceptual framework and a toolkit for supporting the rapid prototyping of context-aware application. *Human–Computer Interaction*, page 97–166.
- Google (2013). Google now. <https://www.google.com/intl/pt-BR/landing/now/>. [Online; acessado em 09 de Junho 2016].
- Hightower, J. and Borriello, G. (2001). Location systems for ubiquitous computing. *Annalen der Physik*, page 57–66.
- Horvitz, E. and Krumm, J. (2012). Some help on the way: Opportunistic routing under uncertainty. In *Proceedings of UbiComp'12*.
- Mayrhofer, R. (2004). An architecture for context prediction. *PhD thesis, University of Linz*.
- Mayrhofer, R. (2005). Context prediction based on context histories: Expected benefits, issues and current state-of-the-art. *Cognitive Science Research Paper-University of Sussex CSRP*, page 31.
- Meiners, M., Zaplata, S., and Lamersdorf, W. (2010). Structured context prediction: a generic approach. In *Proceedings of the 10th IFIP WG 6.1 international conference on distributed applications and interoperable systems DAIS'10*, page 84–97.
- Noulas, A., Scellato, S., Lathia, N., and Mascolo, C. (2012). Mining user mobility features for next place prediction in location-based services. In *Proceedings of ICDM'12*.
- Pejovic, V. and Musolesi, M. (2015). Anticipatory mobile computing: A survey of the state of the art and research challenges. *ACM Computing Surveys*, pages 1–29.
- Rosa, J. H., Barbosa, J. L. V., and Ribeiro, G. D. (2016). Oracon: an adaptive model for context prediction. *Expert System Application*, page 56–70.
- Silva, J. M., Rosa, J. H., Barbosa, J. L., Barbosa, D. N., and Palazzo, L. A. M. (2010). Content distribution in trail-aware environments. *The Brazilian Computer Society*, page 163–176.
- Wagner, A., Barbosa, J. L. V., and Barbosa, D. N. F. (2014). A model for profile management applied to ubiquitous learning environments. *Expert Systems with Applications*, page 2023–2034.
- Weiser, M. (1991). The computer for the 21st century. *Scientific American*, page 94–104.