

Processamento de Sinais Sociais: Visão Geral, Metodologias e Desafios

Isadora V. e Souza¹, William B. Pereira¹, João C. D. Lima¹

¹Programa de Pós-Graduação em Informática – Universidade Federal de Santa Maria
Av. Roraima, 1000 – 97.105-900 – Santa Maria – RS – Brasil

isouza@inf.ufsm.br, williambortoluzzipereira@gmail.com,
caio@inf.ufsm.br

Abstract. *Social Signal Processing (SSP) is a field which studies the verbal and nonverbal signals from humans during a social interaction. However, it still has many challenges, such as specific sensors, battery life, privacy and others. With increasing use of mobile devices researchers attention arisen in order to solve those challenges. This article provides a channel for the dissemination of knowledge, since the SSP is a broad area to deepen knowledge about human behavior.*

Resumo. *O Processamento de Sinais Sociais (SSP) é uma área que estuda os sinais verbais e não verbais reproduzidos por seres humanos durante uma interação social. A área ainda possui muitos desafios de pesquisa como: sensores específicos, duração de bateria, privacidade, entre outros. Com o crescente uso de dispositivos móveis, a área chamou a atenção dos pesquisadores que estão trabalhando no desenvolvimento de soluções para alguns desses desafios. Este artigo oferece um canal para a disseminação do conhecimento, pois o SSP é uma área ampla para aprofundar os conhecimentos sobre o comportamento humano.*

1. Introdução

A psicologia é a ciência que estuda o comportamento humano. Alguns métodos utilizados pelos pesquisadores são: questionários, observação, imagens obtidas por câmeras, entre outros. Estes métodos podem conter erros causados pela imparcialidade e a indiferença das pessoas que estão sendo avaliadas, como também por restrições de escalabilidade, pois a avaliação não é feita de modo globalizado, esta avaliação é aplicada em um grupo limitado de pessoas.

Para automatizar o processo de avaliação do comportamento humano, surgiu o *Social Signal Processing* (SSP), ou traduzindo, Processamento de Sinais Sociais que é uma área focada em detectar automaticamente as informações sobre o comportamento social dos usuários, visando a não intrusão, ou seja, utiliza-se o máximo de sensores para levantamento de dados para capturar informação dos contextos que o usuário se encontra. O SSP soluciona os problemas de imparcialidade, indiferença e escalabilidade.

O SSP foi criado não apenas para facilitar o trabalho dos pesquisadores da área de psicologia, mas também para diversas outras áreas, como saúde, engenharia organizacional e marketing, por exemplo. Existem aplicações de monitoramento de frequência cardíaca, pressão, atividade física, outras para medir o nível de satisfação em um ambiente de trabalho e também para ajustar campanhas de determinado produto ou serviço de acordo com o humor e as preferências do usuário.

O artigo está dividido da seguinte forma: na seção 2 é apresentada uma visão geral de Processamento de Sinais Sociais, na seção 3 há um compilado de trabalhos que utilizaram o SSP, na seção 4 os desafios da área e na seção 5 a conclusão.

2. Visão Geral

O Processamento de Sinais Sociais utiliza inúmeros sensores para o levantamento de dados do comportamento do usuário. Segundo [Schuster 2013], o SSP analisa o comportamento humano baseado em pistas verbais e não verbais de baixo nível, como a fala do usuário, piscar e sorrir com o objetivo de detectar comportamentos de alto nível, como atividade física, engajamento e estresse.

Para o SSP é fundamental que a aplicação seja oportunística e não intrusiva, ou seja, que a aplicação levante os dados sem a intervenção do usuário e sem atrapalhar o seu comportamento habitual do cotidiano, quanto maior a naturalidade do processo, maior a legitimidade dos dados adquiridos. Sendo assim, a computação móvel é um dos principais meios de coleta de dados, pois já é uma ferramenta de uso recorrente pelo usuário.

O *SSP Mobile* possui os seguintes objetivos: utilizar abordagens não intrusivas, capturar dados da perspectiva do usuário para produzir dados personalizados, utilizar múltiplas modalidades para extrair informações mais robustas e confiáveis do comportamento, processo de inferência e sensoriamento contínuo, sem restrições de mobilidade e escalabilidade e eliminar a necessidade de hardwares externos.

Vinciarelli (2010) definiu alguns procedimentos para a detecção de comportamento social, que mais tarde foram adaptados para o meio *Mobile* por [Palaghias 2014], que concluíram que para extrair conhecimentos sobre comportamento social em dispositivos móveis são necessários quatro passos:

1. Sensoriamento
2. Detecção de interação social
3. Extração de pistas comportamentais
4. Obtenção de conhecimento sobre comportamento social através de inferência de sinais sociais

O sensoriamento (passo 1) é feito pelos sensores presentes no dispositivo, como giroscópio, acelerômetro, câmera, microfone, etc. Cada sensor é responsável por gerar os dados de determinadas características, como por exemplo o microfone vai gerar os dados referentes à fala do usuário.

A detecção de interação social (passo 2) pode ser realizada de diversas maneiras, pode ser utilizando uma modalidade única ou modalidades múltiplas. Na modalidade única são utilizados conexões Bluetooth ou Wi-Fi para identificar pessoas próximas. Na modalidade múltipla são utilizados conexões Bluetooth e Wi-Fi, microfone, câmera, entre outros sensores. O levantamento de dados de interações sociais possibilitam a extração de pistas comportamentais (passo 3), que são características, hábitos ou padrões de interações do usuário com as pessoas.

Durante uma interação social deve ser levado em conta não apenas o diálogo, mas também os gestos, as feições, o direcionamento da fala, etc. Todos esses atributos são chamados de sinais sociais. Pentland (2008) descreve sinais sociais como sinais de comunicação não-verbal emitidos quando as pessoas estão interagindo socialmente. A

união destes sinais sociais por um período de tempo leva ao conhecimento do comportamento social (passo 4). A Figura 1 apresenta alguns sinais sociais reproduzidos durante uma interação, como: características da postura, olhar mútuo, comportamento verbal, etc.




Figura 1. Representação de Sinais Sociais. [Zhou 2010]

A arquitetura do *SSP Mobile* possui quatro bases principais: o framework de sensoriamento, as interações sociais, as pistas comportamentais e os comportamentos sociais inferidos pelos sinais sociais (ver Figura 2). O framework de sensoriamento é necessário para coletar e armazenar dados brutos de sensores ambientais (microfone, câmera), sensores de posição (Bluetooth, GPS, WiFi), sensores virtuais (informação de chamadas, SMS, uso do celular) e inerciais (acelerômetro, giroscópio) e utilizá-los para fazer a inferência de sinais sociais, por exemplo: coletar dados do acelerômetro para inferir que o usuário está realizando determinado gesto.

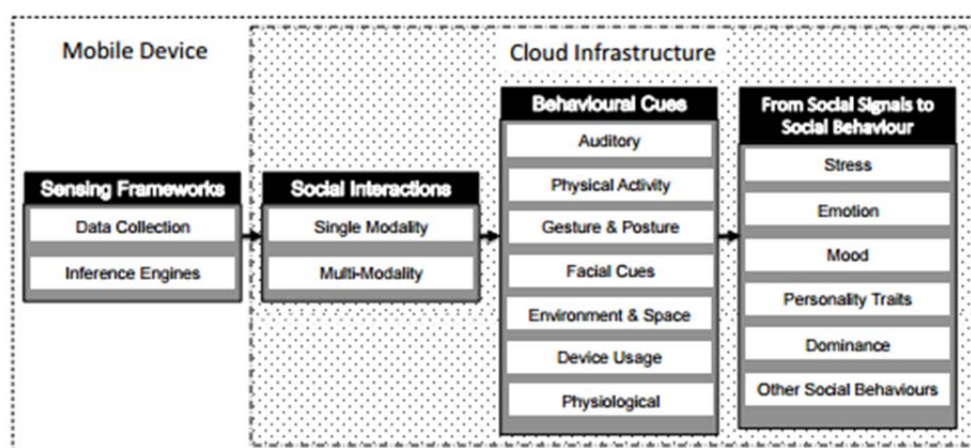


Figura 2. Arquitetura do SSP Mobile. [Palaghias 2014]

As interações sociais são inferidas com base nos sinais sociais previamente levantados pelo framework de sensoriamento. As interações podem ser inferidas por meio de modalidade única ou por modalidade múltipla. Na modalidade única são considerados apenas dados de sensores de posição, principalmente Bluetooth e WiFi, para inferir se as pessoas integrantes da interação estão próximas. Na modalidade múltipla, são

considerados outros tipos de sensores além dos sensores de posição, como sensores ambientais para obter dados do diálogo dos integrantes.

As pistas comportamentais representam informações sobre atividades físicas, fala, gestos, postura, pistas faciais (piscar, sorrir), condições ambientais e espaciais e uso do dispositivo móvel. Essas informações são necessárias para a inferência de características complexas, como: estresse, emoção, humor, traços de personalidade, domínio, entre outras.

3. Exemplos Práticos

O processamento, sensoriamento e monitoramento feito por dispositivos móveis estão naturalmente sendo inseridos na vida dos usuários, abrindo espaço para o desenvolvimento de aplicações que facilitam o cotidiano em várias esferas. Os trabalhos relacionados foram selecionados com o objetivo de demonstrar a abrangência da área de Processamento de Sinais Sociais, destacando sua importância para várias áreas do conhecimento. A Tabela 1 representa um quadro comparativo entre eles.

Tabela 1. Quadro Comparativo dos Trabalhos Relacionados

Sistemas	Sensores	Objetivo	Dados Coletados
SPA	Oxímetro de pulso, medidor de pressão arterial, acelerômetro, temperatura, umidade, luz e GPS	Monitoramento de saúde	Ambientais e biomédicos
BALANCE	MSP box: acelerômetro 3D, barômetro, umidade, luz e GPS	Auxiliar emagrecimento	Calorias consumidas e adquiridas
StudentLife	Acelerômetro, GPS, microfone, proximidade e luz	Pesquisa de saúde mental	Dados do cotidiano do usuário
Social Serendipity	Bluetooth e WiFi	Rede social	Interesses do usuário
Sociômetros	Transmissor de rádio de alta frequência e microfone	Pesquisa de diferença entre gêneros	Discurso e proximidade dos usuários

O SPA de Sha (2008) monitora continuamente o corpo, o comportamento e o ambiente do usuário durante as suas atividades diárias e notifica profissionais de saúde, caso ocorra alguma emergência. A arquitetura do SPA é composta por uma rede de sensores no corpo do usuário para coletar dados ambientais e biomédicos, um servidor remoto que armazena e analisa os dados dos sensores e um grupo de profissionais de saúde que observam os registros feitos pelo SPA e dão conselhos aos usuários para melhorarem suas condições de saúde.

Assim como o SPA, o BALANCE de Denning (2009) também é um aplicativo voltado para a área da saúde, porém tem o objetivo de fornecer uma maneira fácil de

visualizar as calorias consumidas e gastas durante o dia para auxiliar no processo de emagrecimento dos usuários. O aplicativo possui uma base de dados de alimentos com suas devidas calorias e o usuário seleciona os que foram consumidos. O BALANCE utiliza *Mobile Sensing Platform* (MPS) para calcular as calorias gastas em atividades como sentado, andando, correndo e andando de bicicleta.

O StudentLife de Wang (2014) é uma aplicação desenvolvida para pesquisa. Ele faz o sensoramento contínuo da saúde mental, performance acadêmica e tendências comportamentais dos estudantes. O aplicativo infere atividades como parado, caminhando, correndo, dirigindo e andando de bicicleta e a duração do sono. Além de capturar o áudio e utilizar modelo oculto de Markov para inferir conversações para obter dados da socialização do usuário. Informações sobre o uso do dispositivo móvel também são avaliadas. Os pesquisadores perceberam que estas características influenciam no bem estar e na saúde mental do usuário.

O Social Serendipity de Eagle & Pentland (2005) é uma aplicação que utiliza endereços de hardware Bluetooth e um banco de dados de perfis de usuários que tem o objetivo de viabilizar as interações casuais face a face entre os usuários próximos que não se conhecem, mas deveriam se conhecer pois possuem muitas características em comum. O Serendipity utiliza um servidor centralizado para coordenar as interações sociais locais. O servidor guarda os perfis dos usuários com dados necessários para fazer a combinação destes perfis, como as variáveis de atributos que definem os interesses e o ID do Bluetooth (BTID) do dispositivo. Quando dois usuários do Serendipity se aproximam, o servidor verifica se as pessoas têm interesses e gostos em comum através de uma pontuação de semelhança das variáveis, caso tenham, um sinal é enviado para ambos os dispositivos.

Os Sociômetros de Onnela (2014) são dispositivos portáteis que capturam as pessoas próximas através de um transmissor de rádio de alta frequência e um microfone para acompanhar o discurso dos usuários dentro de contextos específicos. Eles auxiliam nas pesquisas de interação humana, antes feitas através de relatos dos indivíduos. Os auto relatos estão propensos a erros, sendo assim, reduzem a gama de comportamentos e o número de assuntos que podem ser estudados simultaneamente. O objetivo deste estudo com os sociômetros é encontrar algumas diferenças entre os gêneros (masculino e feminino), como loquacidade e estilo de interação em contextos diferentes.

4. Desafios

Com o aumento do mercado de dispositivos móveis nos últimos anos, a área de computação móvel vem ganhando cada vez mais foco de pesquisa. No entanto, ainda existem algumas necessidades e desafios a serem supridos, como: reconhecimento de contexto, precisão de sensores, gerenciamento de bateria, privacidade.

O reconhecimento de contexto é fundamental para o SSP mas também é um grande desafio para a área por ter um amplo sentido do termo. Uma medida que os pesquisadores vem tomando é limitar o âmbito da aplicação, por exemplo: uma aplicação para monitorar a produtividade em determinada empresa.

A tecnologia mais importante para a área de Processamento de Sinais Sociais é o sensor. Atualmente existem inúmeros sensores disponíveis, porém eles são extremamente suscetíveis a erros por não terem o nível de precisão adequado para o sensoramento de sinais sociais. Por exemplo, o GPS não possui precisão suficiente quando o usuário está dentro de um edifício (vários andares) ou um túnel (sem sinal). Outro ponto, é que ainda

não foram desenvolvidos sensores adequados para detectar os sinais sociais e as atividades do usuário. Para os sinais sociais, estão sendo utilizados sensores invasivos para obter uma melhor acurácia, isso prejudica a naturalidade do sinal. Para as atividades como correndo e andando, estão sendo utilizados alguns sensores como acelerômetro mas ainda com um baixo nível de acurácia.

Outro problema relacionado aos sensores é a fusão de modalidades. O crescente poder computacional dos dispositivos móveis viabilizou a criação de muitos sensores de várias modalidades, o desafio é a união de modalidades de sensores físicos e virtuais mantendo a precisão de inferência de comportamento.

O gerenciamento de bateria é um grande problema da área, pois o SSP utiliza vários sensores e o consumo de bateria nos dispositivos móveis é elevado. As aplicações precisam criar mecanismos para habilitar e desabilitar os sensores de acordo com a necessidade, para não desperdiçar energia. O processamento dos dados dos sensores é, na maioria dos casos, feito em servidores para não consumir energia com processamento. Porém estas medidas não são suficientes em aplicações que precisam detectar várias características no cotidiano do usuário.

A privacidade é também um desafio, pois as aplicações tendem a ser oportunistas, ou seja, capturar dados sem a intervenção do usuário para poder capturar dados de ações realizadas naturalmente. Por isso é preciso ter o consentimento do usuário, garantir o seu anonimato e não enviar dados a aplicativos de terceiros.

5. Conclusão

O Processamento de Sinais Sociais e os dispositivos móveis formaram uma promissora ferramenta para o estudo do comportamento humano, pois os dispositivos são pervasivos, onipresentes e discretos. Porém, há um longo caminho para satisfazer os desafios da área, tanto no desenvolvimento de hardware (sensores, bateria), quanto no desenvolvimento de middlewares e frameworks para facilitar a manipulação de dados em baixo nível. Em conjunto com a psicologia, a mineração e inferência de dados coletados, o SSP tem muito potencial para aprofundar os conhecimentos referentes aos seres humanos.

Referências Bibliográficas

- Denning, T., Andrew, A., Chaudhri, R., Hartung, C., Lester, J., Borriello, G., & Duncan, G. (2009). BALANCE: Towards a Usable Pervasive Wellness Application with Accurate Activity Inference. In Proceedings of the 10th workshop on Mobile Computing Systems and Applications. ACM.
- Eagle, N., & Pentland, A. (2005). Social Serendipity: Mobilizing Social Software. IEEE Pervasive Computing.
- Onnela, J. P., Waber, B. N., Pentland, A., Schnorf, S., & Lazer, D. (2014). Using Sociometers to Quantify Social Interaction Patterns. Scientific reports.
- Palaghias, N., Hoseinitabatabaei, S. A., Nati, M., Gluhak, A., & Moessner, K. (2016). A Survey on Mobile Social Signal Processing. ACM Computing Surveys (CSUR).
- Pentland, A., & Heibeck, T. (2010). Honest Signals: How They Shape our World. MIT Press.

- Schuster, D., Rosi, A., Mamei, M., Springer, T., Endler, M., & Zambonelli, F. (2013). Pervasive Social Context: Taxonomy and Survey. *ACM Transactions on Intelligent Systems and Technology (TIST)*.
- Sha, K., Zhan, G., Shi, W., Lumley, M., Wiholm, C., & Arnetz, B. (2008). SPA: A Smartphone Assisted Chronic Illness Self-Management System with Participatory Sensing. In *Proceedings of the 2nd International Workshop on Systems and Networking Support for Health Care and Assisted Living Environments*. ACM.
- Vinciarelli, A., Murray-Smith, R., & Bourlard, H. (2010). Mobile Social Signal Processing Vision and Research Issues. In *Proceedings of the 12th international conference on Human computer interaction with mobile devices and services*. ACM.
- Wang, R., Chen, F., Chen, Z., Li, T., Harari, G., Tignor, S., & Campbell, A. T. (2014). StudentLife: Assessing Mental Health, Academic Performance and Behavioral Trends of College Students Using Smartphones. In *Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing*. ACM.
- Zhou, J., Sun, J., Athukorala, K., Wijekoon, D., & Ylianttila, M. (2012). Pervasive Social Computing: Augmenting Five Facets of Human Intelligence. *Journal of Ambient Intelligence and Humanized Computing*.