

Ranqueamento de Recursos IOT: Explorando Aprendizagem de Máquina e Algoritmos MCDA

Felipe C. Gruendemann, Juan Burtet,
Renato Dilli, Adenauer Yamin

¹Laboratory of Ubiquitous and Parallel Systems – UFPEL
Pelotas, RS - Brasil

{fcgruendemann, jburtet, renato.dilli, adenauer}
@inf.ufpel.edu.br

Resumo. *O cenário atual da IoT impõe desafios referentes ao ranqueamento de recursos e serviços. Nesse trabalho são explorados Algoritmos MCDA e de Aprendizagem de Máquina para classificação de um conjunto de dados com o intuito de investigar alternativas para contribuir com a arquitetura do middleware EXEHDA. Foram realizados testes que apontaram a acurácia e desempenho das abordagens adotadas, demonstrando que essas abordagens são candidatas à inclusão na arquitetura.*

1. Introdução

A Internet das Coisas (*IoT – Internet of Things*), é caracterizada por ser um ambiente que apresenta uma grande quantidade de objetos, os quais efetuam conexões transitórias na Internet e resultam em um número elevado de serviços disponibilizados [Perera 2017]. No cenário atual existem mais de seis bilhões de objetos conectados à Internet e constantemente fornecendo serviços aos clientes, havendo a previsão de alcançar 100 bilhões até 2025 [BIS Research 2017]. Este cenário demonstra a relevância do desenvolvimento de estudos e pesquisas para cooperar com os mecanismos de seleção de recursos visando uma alta escalabilidade em ambientes de constituição heterogênea [de Andrade Junior et al. 2014].

Para realizar a seleção do melhor recurso nesta infraestrutura provida pela Internet, o processo de descoberta e ranqueamento de recursos precisa analisar tanto os requisitos funcionais, quanto os não-funcionais. Assim, após a devida identificação e localização dos recursos, é necessário classificá-los em ordem de Qualidade de Serviço (QoS).

A Análise de Decisão de Múltiplos Critérios (*MCDA - Multiple Criteria Decision Analysis*) refere-se à tomada de decisões na presença de critérios múltiplos, geralmente conflitantes. Os algoritmos MCDA visam auxiliar no julgamento da tomada de decisão utilizando um conjunto de objetivos e critérios, estimando seus pesos de importância relativa e estabelecendo a contribuição de cada opção em relação a cada critério de desempenho. MCDA é uma perspectiva específica para lidar com problemas de tomada de decisão [Figueira et al. 2005].

Por sua vez, a aprendizagem de máquina tem como objetivo entender a lógica dos programas para aprimorar o desempenho das máquinas em determinadas tarefas, através de experiência prévia [Suchithra and Ramakrishnan 2015].

Considerando todos esses fatores, tomou-se como objetivo central deste trabalho explorar alternativas para contribuir com a arquitetura de software do mecanismo de descoberta de recursos do *middleware* EXEHDA, em desenvolvimento no grupo de pesquisa utilizando abordagens MCDA e de Árvores de Decisão.

2. Trabalho Desenvolvido

Em uma primeira etapa da pesquisa foi realizada uma revisão bibliográfica dos conceitos sobre Internet das Coisas, Descoberta e Ranqueamento de Recursos, *Middleware* EXEHDA, Algoritmos de Árvore de Decisão e Algoritmos de Decisão de Multicritérios (MCDA).

Após a revisão bibliográfica, foram analisados algoritmos de Árvores de Decisão e algoritmos MCDA. Foram feitas abordagens para geração e ranqueamento de recursos no contexto da IoT, com objetivo de avaliar o desempenho do algoritmo MCDA proposto. Para a parte que trata de MCDA foi concebido um método de ranqueamento, um gerador e classificador para o ranqueamento de recursos.

Já para os algoritmos de Árvore de Decisão foi feita a análise de algoritmos selecionados. Os algoritmos analisados foram aplicados sobre o *dataset Quality of Web Service*(QWS) usando a ferramenta de *Data Mining WEKA*. O objetivo da análise foi verificar o tempo de construção de modelo e a acurácia dos algoritmos na classificação de serviços considerando os valores de atributos de QoS (*Quality of Service*).

3. Análise e resultados obtidos

3.1. Algoritmo MCDA

O processo de descoberta de recursos engloba a seleção dos recursos mais adequados à requisição do cliente considerando os indicadores de qualidade de serviço. Nesta seção é apresentado o algoritmo MCDA proposto para o processo de ranqueamento de recursos utilizado neste trabalho. O algoritmo MCDA proposto é uma adaptação dos algoritmos *The Simple Additive Weighting* (SAW) [Tzeng and Huang 2011] e *Web Service Relevancy Function*(WsRF) [Al-Masri and Mahmoud 2007], com a primeira etapa de normalização de dados proposta por [Liu et al. 2004].

Com objetivo de analisar o desempenho do modelo de ranqueamento proposto, foi concebido um gerador de *dataset* que produz, utilizando a biblioteca *random*, um conjunto de recursos com atributos de valores pseudo-aleatórios. Os valores dos atributos desses recursos respeitam um intervalo de valores mínimo e máximo definidos. Registre-se que estes valores mínimo e máximo tem por base um *dataset* (QWS) que traduz um cenário real de *Web Services*. Ao fim da criação do conjunto de teste, é efetuado o ranqueamento dos recursos gerados.

Com o emprego do programa desenvolvido para geração de recursos, foram criados 4 conjuntos com seus atributos de qualidade. Para o processo de criação destes recursos, optou-se por utilizar conjuntos com 3, 5 e 7 atributos com o objetivo de apontar a diferença de tempo no cálculo MCDA considerando diferentes quantidades de atributos. Além disso, foram criados datasets de tamanhos diferentes para analisar o aumento de tempo para conjuntos com diferentes quantidades de recursos e com mesmo número de atributos. O tamanho dos datasets testados foram de [10.000; 100.000; 500.000;

1.000.000] recursos. Com a análise dos resultados, foi notado que houve um aumento linear no tempo de geração e ranqueamento, conforme o aumento do número de recursos, como ilustrado na Tabela 1.

Tabela 1. Tempo de ranqueamento dos recursos

Atrib	Recursos (x 1.000)			
	10	100	500	1.000
3	0.10s	1.01s	5.15s	10.08s
5	0.15s	1.44s	7.20s	14.50s
7	0.18s	1.88s	9.59s	18.79s

Os testes dos algoritmos MCDA foram feitos em uma máquina com processador Intel I5-3570K CPU @ 3.40 GHz e memória RAM de 4GB.

3.2. Aprendizagem de Máquina

Identificou-se que os algoritmos de Árvore de Decisão são uma opção conveniente para a classificação de recursos. Estes algoritmos são adequados para problemas que envolvem a classificação baseada em decisão e aprendizado adaptativo em um conjunto de treinamento. A árvore de decisão é uma solução bem conhecida para implementar essas táticas, e é uma ferramenta de modelagem de decisão que mostra graficamente o processo de classificação de uma determinada entrada para determinados rótulos de classe de saída [Witten et al. 2016].

Utilizando a ferramenta WEKA foram analisados alguns dos algoritmos de árvore de decisão que o *software* dispõe, ilustrados na Figura 1. A classificação dos serviços foi realizada pelos algoritmos a fim de classificar o atributo *Service Classification* dentre outros cinco atributos do conjunto de dados analisado. Para execução dos testes foram utilizadas as configurações padrão da ferramenta WEKA. Os testes foram executados com datasets de 800, 900 e 1000 recursos para cada um dos algoritmos mencionados. Nos resultados dos testes pode se observar que o algoritmo que, em média, obteve a melhor acurácia foi o LMT. Contudo esse foi também o algoritmo com o mais elevado tempo de construção de modelo. Outros algoritmos que obtiveram acurácia elevada foram o *Random Forest* e o FT, mantendo um tempo de construção de modelo bastante inferior comparado ao LMT.




Figura 1. Acurácia dos Algoritmos.

4. Considerações Finais

A contribuição central desse trabalho foi explorar algoritmos de Árvore de Decisão e algoritmos MCDA, tendo como perspectiva seu emprego na Classificação de Recursos na IoT para contribuição na arquitetura de *software* do mecanismo de descoberta de recursos do *middleware* EXEHDA.

A utilização do algoritmo MCDA proposto para a classificação de recursos no contexto da Internet das Coisas apresentou um bom desempenho, considerando a literatura na área e as necessidades do grupo de pesquisa, mesmo com um grande aumento no conjunto de dados e no número de atributos de qualidade.

Os testes com os algoritmos de Árvore de Decisão aplicados à classificação de recursos apontaram uma acurácia média acima de 80%, o que por se tratar de uma pré-classificação atende as demandas do grupo referentes a otimização de desempenho do *middleware* quanto ao ranqueamento de recursos. Também ficou caracterizado que os algoritmos LMT e *Random Forest* foram os que apresentaram melhores resultados. Sendo que o LMT teve um maior tempo de execução e acurácia média superior se comparado ao *Random Forest*.

Como atividades futuras pretende se desenvolver uma metodologia de ranqueamento de recursos utilizando MCDA e Árvores de Decisão para integrar a arquitetura do *middleware* EXEHDA em desenvolvimento no grupo de pesquisa.

Referências

- Al-Masri, E. and Mahmoud, Q. H. (2007). QoS-based discovery and ranking of Web services. In *Proceedings - International Conference on Computer Communications and Networks, ICCCN*, pages 529–534.
- BIS Research (2017). Global Sensors in Internet of Things (IoT) Devices Market, Analysis & Forecast: 2016 to 2022. Technical report.
- de Andrade Junior, N. V., Bastos, D. B., and Prazeres, C. V. S. (2014). Web of Things: Automatic Publishing and Configuration of Devices. *Proceedings of the 20th Brazilian Symposium on Multimedia and the Web*, pages 67–74.
- Figueira, J., Greco, S., and Ehrgott, M. (2005). Multiple criteria decision analysis: state of the art surveys. *Multiple Criteria Decision Analysis State of the Art Surveys*, 78.
- Liu, Y., Ngu, A. H., and Zeng, L. Z. (2004). QoS computation and policing in dynamic web service selection. *Proceedings of the 13th international World Wide Web conference on Alternate track papers & posters*, pages 66–73.
- Perera, C. (2017). *Sensing as a Service for Internet of Things: A Roadmap*. Leanpub Publishers.
- Suchithra, M. and Ramakrishnan, M. (2015). A survey on different web service discovery techniques. *Indian Journal of Science and Technology*, 8(15):1–5.
- Tzeng, G. H. and Huang, J. J. (2011). *Multiple Attribute Decision Making: Methods and Applications*. A Chapman & Hall book. Taylor & Francis.
- Witten, I. H., Frank, E., and Hall, M. A. (2016). The WEKA Workbench. *Morgan Kaufmann, Fourth Edition*, pages 553–571.